

Министерство образования и науки Российской Федерации Федеральное государственное бюджетное образовательное учреждение высшего образования

«Московский государственный технический университет имени Н.Э. Баумана

(национальный исследовательский университет)» (МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ

ИНФОРМАТИКА И СИСТЕМЫ УПРАВЛЕНИЯ

КАФЕДРА СИСТЕМЫ ОБРАБОТКИ ИНФОРМАЦИИ И УПРАВЛЕНИЯ

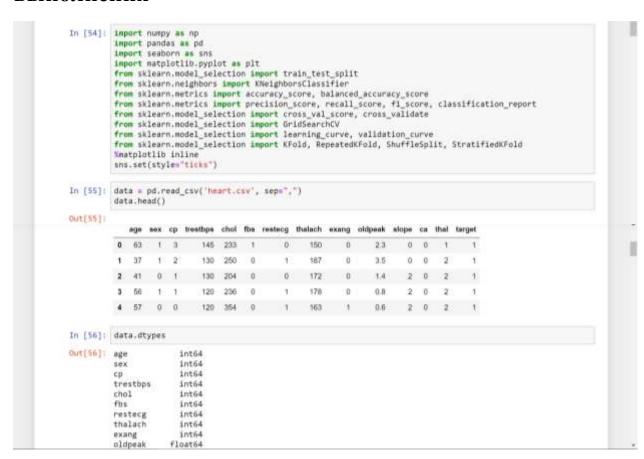
Отчет по лабораторной работе № 4 «Подготовка обучающей и тестовой выборки, кросс-валидация и подбор гиперпараметров на примере метода ближайших соседей» по курсу "Технологии машинного обучения"

Исполнитель: Студент группы ИУ5-63 Желанкина А.С. 21.03.2019

Задание лабораторной работы

- 1. Выберите набор данных (датасет) для решения задачи классификации или регресии.
- 2. В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
- 3. С использованием метода train_test_split разделите выборку на обучающую и тестовую.
- 4. Обучите модель ближайших соседей для произвольно заданного гиперпараметра К. Оцените качество модели с помощью трех подходящих для задачи метрик.
- 5. Постройте модель и оцените качество модели с использованием кроссвалидации. Проведите эксперименты с тремя различными стратегиями кроссвалидации.
- 6. Произведите подбор гиперпараметра К с использованием GridSearchCV и кросс-валидации.
- 7. Повторите пункт 4 для найденного оптимального значения гиперпараметра К. Сравните качество полученной модели с качеством модели, полученной в пункте 4.
- 8. Постройте кривые обучения и валидации.

Экранные формы с текстом программы и примерами её выполнения



```
slope
           ca
thal
                            int64
                            int64
            target
                            int64
           dtype: object
In [57]: data.shape
Out(57): (303, 14)
In [58]: data.isnull().sum()
Out[58]: age
           co
                          a
            trestbps
            cho1
            fos
                          15
           resteck
                          0
            thalach
            exang
           oldpeak
            slope
            thal
            target
           dtype: int64
In [60]: X_train.shape, y_train.shape, X_test.shape, y_test.shape
Out[60]: ((242, 14), (242,), (61, 14), (61,))
In [61]: simple_knn = KNeighborsClassifier()
In [62]: simple_knn.fit(X_train, y_train)
Out[62]: KNeighborsClassifier(algorithm='auto', leaf_size=30, metric='minkowski', metric_params=None, n_jobs=None, n_neighbors=5, p=2, weights='uniform')
In [63]: target_1 = simple_knn.predict(X_test)
In [64]: accuracy_score(y_test, target_1), \
    precision_score(y_test, target_1), \
            recall_score(y_test, target_1)
Out[64]: (0.5737704918032787, 0.5675675675675675, 0.6774193548387096)
In [65]: kfold = cross_val_score(KNeighborsClassifier(),
                                         data, data['target'],
cv=KFold(n_splits=5))
            kfold.
Out[65]: array([0.47540984, 0.63934426, 0.68852459, 0.4
                                                                          , 0.31666667])
In [66]: shufflesplit = cross_val_score(KNeighborsClassifier(),
                                         data, data['target'],
cv=ShuffleSplit(n_splits=5, test_size=0.2))
            shufflesplit
Out[66]: array([0.57377049, 0.72131148, 0.67213115, 0.62295082, 0.6557377 ])
In [67]: stratifiedkfold = cross_val_score(KNeighborsClassifier(),
                                         data, data['target'],
cv=StratifiedKFold(n_splits=5))
            stratifiedkfold
Out[67]: array([0.60655738, 0.6557377 , 0.57377049, 0.73333333, 0.65
In [68]: n_range = np.array(range(1,10,1))
  tuned_parameters = [{'n_neighbors': n_range}]
  clf_gs = GridSearchCV(KNeighborsClassifier(), tuned_parameters,
                                      cv=StratifiedKFold(n_splits=5), scoring='accuracy')
            clf_gs.fit(X_train, y_train)
           C:\Anaconda\lib\site-packages\sklearn\model_selection\_search.py:841: DeprecationWarning: The default of the 'iid' parameter will change from True to False in version 8.22 and will be removed in 8.24. Th is will change numeric results when test-set sizes are unequal.
             DeprecationWarning)
Out[68]: GridSearchCV(cv=StratifiedXFold(n_splits=5, randon_state=None, shuffle=False),
                    error_score='raise-deprecating',
                    estimator=KNeighborsClassifier(algorithm='auto', leaf_size=30, metric='minkowski',
                         metric_params=None, n_jobs=None, n_neighbors=5, p=2,
```

```
weights='uniform'),
                     fit_params=None, lid='warn', n_jobs=None,
param_grid=[{'n_neighbors': array([1, 2, 3, 4, 5, 6, 7, 8, 9])}],
pre_dispatch='2*n_jobs', refit=True, return_train_score='warn',
                     scoring='accuracy', verbose=0)
In [69]: clf_gs.best_params_
Out[69]: ('n_neighbors': 3)
In [78]: simple_knn_best = KNeighborsClassifier(n_neighbors*3)
In [71]: simple_knn_best.fit(X_train, y_train)
Out[71]: KNeighborsClassifier(algorithm='auto', leaf_size=30, metric='minkowski', metric_parans=None, n_jobs=None, n_neighbors=3, p=2,
                          weights='uniform')
In [72]: target_2 = simple_knn_best.predict(X_test)
In [73]: accuracy_score(y_test, target_2), \
            precision_score(y_test, target_2),
recall_score(y_test, target_2)
Out[73]: (0.5737704918032787, 0.56097560976, 0.7419354838709677)
In [74]: def plot_learning_curve(estimator, title, X, y, ylimeNone, cveNone,
                                          n_jobs=None, train_sizes=np.linspace(.1, 1.0, 5)):
                 Generate a simple plot of the test and training learning curve.
                 Parameters
                 estimator : object type that implements the "fit" and "predict" methods 
 An object of that type which is closed for each validation.
                 title : string
Title for the chart.
                 X : array-like, shape (n_samples, n_features)
                      Training vector, where n_samples is the number of samples and
Out[78]: <module 'matplotlib.pyplot' from 'C:\\Anaconda\\lib\\site-packages\\matplotlib\\pyplot.py'>
               0.80
               0.75
               0.78
               0.65
               0.60
               0.55
                                             900
In [76]: def plot_validation_curve(estimator, title, X, y,
                                             param_name, param_range, cv,
                                             scoring="accuracy"):
                 train scores, test scores * validation curve(
                      estimator, X, y, param_name=param_name, param_range=param_range,
                 cv=cv, scoring=scoring, n_jobs=1)
train_scores_mean = np.mean(train_scores, axis=1)
train_scores_std = np.std(train_scores, axis=1)
test_scores_mean = np.mean(test_scores, axis=1)
                 test_scores_std = np.std(test_scores, axis=1)
                 plt.title(title)
                 plt.xlabel(param_name)
plt.ylabel("Score")
                 plt.ylin(0.0, 1.1)
                 plt.plot(param_range, train_scores_mean, label="Training score", celor="darkorange", lw=lw)
                 plt.fill_between(param_range, train_scores_mean - train_scores_std,
train_scores_mean + train_scores_std, alpha=0.2,
color="darkorange", lw=lw)
```

