

Министерство образования и науки Российской Федерации Федеральное государственное бюджетное образовательное учреждение высшего образования

«Московский государственный технический университет имени Н.Э. Баумана

(национальный исследовательский университет)» (МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ

ИНФОРМАТИКА И СИСТЕМЫ УПРАВЛЕНИЯ

КАФЕДРА СИСТЕМЫ ОБРАБОТКИ ИНФОРМАЦИИ И УПРАВЛЕНИЯ

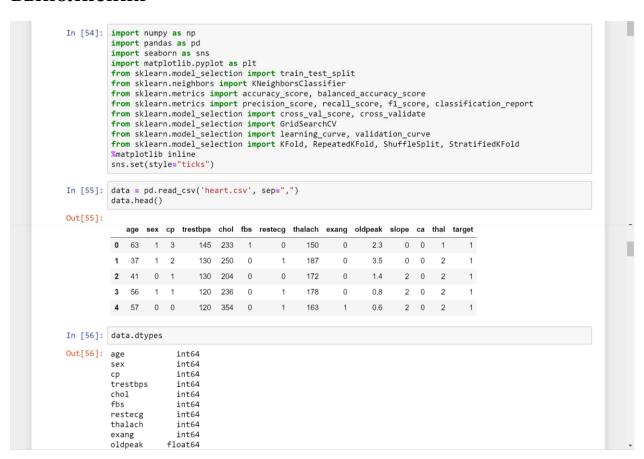
Отчет по лабораторной работе № 4 «Подготовка обучающей и тестовой выборки, кросс-валидация и подбор гиперпараметров на примере метода ближайших соседей» по курсу "Технологии машинного обучения"

Исполнитель: Студент группы ИУ5-63 Желанкина А.С. 21.03.2018

Задание лабораторной работы

- 1. Выберите набор данных (датасет) для решения задачи классификации или регресии.
- 2. В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
- 3. С использованием метода train_test_split разделите выборку на обучающую и тестовую.
- 4. Обучите модель ближайших соседей для произвольно заданного гиперпараметра К. Оцените качество модели с помощью трех подходящих для задачи метрик.
- 5. Постройте модель и оцените качество модели с использованием кроссвалидации. Проведите эксперименты с тремя различными стратегиями кроссвалидации.
- 6. Произведите подбор гиперпараметра К с использованием GridSearchCV и кросс-валидации.
- 7. Повторите пункт 4 для найденного оптимального значения гиперпараметра К. Сравните качество полученной модели с качеством модели, полученной в пункте 4.
- 8. Постройте кривые обучения и валидации.

Экранные формы с текстом программы и примерами её выполнения



```
slope
                         int64
          са
                         int64
          thal
                         int64
          target
                         int64
          dtype: object
In [57]: data.shape
Out[57]: (303, 14)
In [58]: data.isnull().sum()
Out[58]: age
          ср
                       0
          trestbps
                       0
          chol
          fbs
                       0
          restecg
                       0
          thalach
          exang
                       0
          oldpeak
                       0
          slope
          ca
                       a
          thal
                       0
          target
          dtype: int64
In [60]: X_train.shape, y_train.shape, X_test.shape, y_test.shape
Out[60]: ((242, 14), (242,), (61, 14), (61,))
In [61]: simple_knn = KNeighborsClassifier()
In [62]: simple_knn.fit(X_train, y_train)
Out[62]: KNeighborsClassifier(algorithm='auto', leaf_size=30, metric='minkowski',
                      metric_params=None, n_jobs=None, n_neighbors=5, p=2,
weights='uniform')
In [63]: target_1 = simple_knn.predict(X_test)
In [64]: accuracy_score(y_test, target_1), \
          precision_score(y_test, target_1),
          recall_score(y_test, target_1)
Out[64]: (0.5737704918032787, 0.5675675675675675, 0.6774193548387096)
In [65]: kfold = cross_val_score(KNeighborsClassifier(),
                                     data, data['target'],
cv=KFold(n_splits=5))
          kfold
Out[65]: array([0.47540984, 0.63934426, 0.68852459, 0.4
                                                                  , 0.31666667])
In [66]: shufflesplit = cross_val_score(KNeighborsClassifier(),
                                     data, data['target'],
cv=ShuffleSplit(n_splits=5, test_size=0.2))
          shufflesplit
Out[66]: array([0.57377049, 0.72131148, 0.67213115, 0.62295082, 0.6557377 ])
In [67]: stratifiedkfold = cross_val_score(KNeighborsClassifier(),
                                     data, data['target'],
cv=StratifiedKFold(n_splits=5))
          stratifiedkfold
Out[67]: array([0.60655738, 0.6557377 , 0.57377049, 0.73333333, 0.65
cv=StratifiedKFold(n_splits=5), scoring='accuracy')
          clf_gs.fit(X_train, y_train)
          C:\Anaconda\lib\site-packages\sklearn\model_selection\_search.py:841: DeprecationWarning: The default of the `iid` parameter will change from True to False in version 0.22 and will be removed in 0.24. Th is will change numeric results when test-set sizes are unequal.
            DeprecationWarning)
{\tt Out[68]:} \  \  {\tt GridSearchCV(cv=StratifiedKFold(n\_splits=5, \ random\_state=None, \ shuffle=False),}
                  error_score='raise-deprecating',
                  estimator=KNeighborsClassifier(algorithm='auto', leaf_size=30, metric='minkowski',
                      metric_params=None, n_jobs=None, n_neighbors=5, p=2,
```

```
weights='uniform'),
                 fit_params=None, iid='warn', n_jobs=None,
param_grid=[{'n_neighbors': array([1, 2, 3, 4, 5, 6, 7, 8, 9])}],
pre_dispatch='2*n_jobs', refit=True, return_train_score='warn',
                 scoring='accuracy', verbose=0)
In [69]: clf_gs.best_params_
Out[69]: {'n_neighbors': 3}
In [70]: simple_knn_best = KNeighborsClassifier(n_neighbors=3)
In [71]: simple_knn_best.fit(X_train, y_train)
Out[71]: KNeighborsClassifier(algorithm='auto', leaf_size=30, metric='minkowski',
                     metric_params=None, n_jobs=None, n_neighbors=3, p=2,
                     weights='uniform')
In [72]: target_2 = simple_knn_best.predict(X_test)
In [73]: accuracy_score(y_test, target_2), \
          precision_score(y_test, target_2),
          recall_score(y_test, target_2)
Out[73]: (0.5737704918032787, 0.5609756097560976, 0.7419354838709677)
In [74]: def plot_learning_curve(estimator, title, X, y, ylim=None, cv=None,
                                   n_jobs=None, train_sizes=np.linspace(.1, 1.0, 5)):
              Generate a simple plot of the test and training learning curve.
              Parameters
              estimator : object type that implements the "fit" and "predict" methods \, An object of that type which is cloned for each validation.
                  Title for the chart.
              X : array-like, shape (n_samples, n_features)
                  Training vector, where n_samples is the number of samples and
Out[78]: <module 'matplotlib.pyplot' from 'C:\\Anaconda\\lib\\site-packages\\matplotlib\\pyplot.py'>
                                  n neighbors=3
            0.80
            0.75
            0.70
            0.65
            0.60
                      Training score
                                    100
                                           125
train scores, test scores = validation curve(
                  estimator, X, y, param_name=param_name, param_range=param_range,
              cv=cv, scoring=scoring, n_jobs=1)
train_scores_mean = np.mean(train_scores, axis=1)
train_scores_std = np.std(train_scores, axis=1)
              test_scores_mean = np.mean(test_scores, axis=1)
              test_scores_std = np.std(test_scores, axis=1)
              plt.title(title)
              plt.xlabel(param_name)
plt.ylabel("Score")
              plt.ylim(0.0, 1.1)
              plt.plot(param_range, train_scores_mean, label="Training score",
```

. . .

